EC 651 : Modélisation Statistique

Guillaume Franchi

Cursus Ingénieur 1ère année

Partie 1 : La régression linéaire

Pré-requis

- Connaissances sur le logiciel R.
- Statistiques descriptives.
- Tests d'hypothèses et estimation.
- Un peu d'algèbre linéaire...

Bibiliographie

- R pour la statistique et la science des données, *François Husson et al.*, Presses Universitaires de Rennes.
- Probabilités, Analyse des données et Statistique, *Gilbert Saporta*, Editions Technip.
- Le polycopié d'*Arnaud Guyader*.

◎ Objectifs

- Expliquer un lien possible entre différentes variables décrivant des phénomènes physiques, biologiques, chimiques, etc...
- Prédire la valeur d'une variable réponse en fonction de variables explicatives.

Enseignement

- Partie 1 : Régression linaire (G. Franchi - 1 CM, 6 TDs).
- Partie 2 : Analyse de variance (ANOVA) (B.Mahieu - 1CM, 6 TDs).

Modalités d'évaluation

- 1 évaluation écrite pour la partie 2 : Analyse de variance.
- 1 projet pour la partie 1 : Régression linéaire.

1. La corrélation linéaire

Exemple (*Investissement publicitaire*)

On a recensé les ventes d'un produit cosmétique ainsi que le budget publicitaire accordé à ce produit sur une durée de 36 mois.

Mois	Budget Pub (€)	Budget Pub mois précédent (€)	Ventes (€)
1	22 742	-	200 392
2	22 133	22 742	204 989
3	24 875	22 133	208 374
4	27 493	24 875	212 876
5	23 128	27 493	229 645
6	43 434	23 128	216 858

Exemple (*Investissement publicitaire*)

Ci-dessous, on a représenté ces valeurs sous forme de *séries temporelles*.

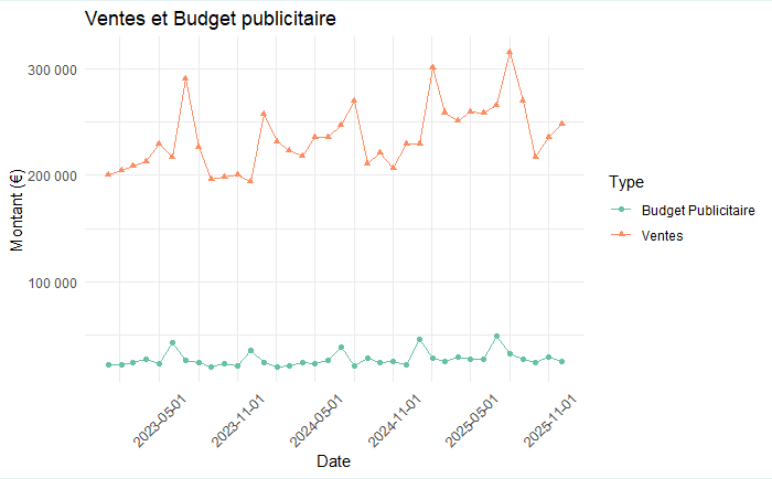

Exemple (*Investissement publicitaire*)

Question : Existe-t-il un lien entre le budget publicitaire et le montant des ventes réalisées ?

- Le nuage de points présentant les ventes réalisées en fonction du budget publicitaire ne montre pas de lien clair...

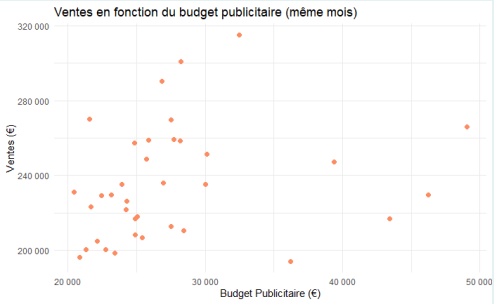

- Le coefficient de corrélation linéaire calculé pour ces deux variables est d'ailleurs $\rho \approx 0,21$.

Définition

Soient X et Y deux variables, dont on possède n observations $x_1, \ldots, x_n$ et $y_1, \ldots, y_n$.

Le **coefficient de corrélation linéaire** entre les variables X et Y est

$$\rho = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2} \times \sqrt{\sum_{i=1}^{n}(y_i - \overline{y})^2}}$$

où $\overline{x}$ et $\overline{y}$ désignent les moyennes des observations des variables X et Y.

Remarques

- ρ est toujours compris entre -1 et 1 : $-1 \leqslant \rho \leqslant 1$.
- ρ mesure à quel point l'égalité $Y = aX + b$ est vraie sur les observations :
  - Si $\rho = 1$, on a $Y = aX + b$ avec $a > 0$.
  - Si $\rho = -1$, on a $Y = aX + b$ avec $a < 0$.
  - Si $\rho = 0$, les observations sont orthogonales (*elles sont non corrélées*).

Exemple (*Investissement publicitaire*)

- On représente maintenant les ventes réalisées chaque mois en fonction du budget publicitaire du mois précédent

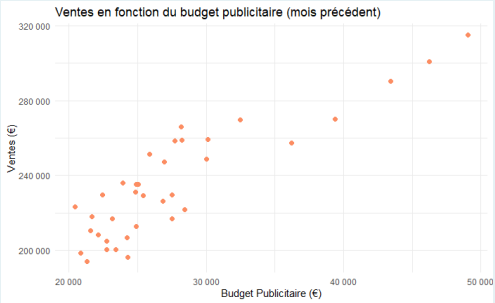

- Le coefficient de corrélation linéaire calculé pour ces deux variables est $\rho \approx 0,88$.

⚙ La corrélation ρ calculée entre X et Y est-elle significativement non nulle, ou cela provient-il d'un effet d'échantillonnage ?

⚙ On se retrouve dans le cadre du test statistique :

$$H_0 : Cor(X, Y) = 0 \quad \text{contre} \quad H_1 : Cor(X, Y) \neq 0.$$

Propriété

Si le vecteur aléatoire (X, Y) est gaussien, on a sous l'hypothèse H_0

$$\frac{\rho}{\sqrt{\frac{1-\rho^2}{n-2}}} \sim \mathcal{T}_{n-2}$$

où $\mathcal{T}_{n-2}$ désigne la loi de Student à $n-2$ d.d.l.

Remarque

On rejettera donc l'hypothèse nulle, au niveau $\alpha > 0$, si

$$\frac{|\rho|}{\sqrt{\frac{1-\rho^2}{n-2}}} > t_{n-2}(1-\alpha/2).$$

Exemple (*Investissement publicitaire*)

On a les sorties R suivantes.

- Corrélation avec le budget publicitaire du même mois :

```r
cor.test(df$`Budget Pub ()`,df$`Ventes ()`)
```

```
 Pearson's product-moment correlation

data:  df$`Budget Pub ()` and df$`Ventes ()`
t = 1.2587, df = 34, p-value = 0.2167
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.1262841  0.5045639
sample estimates:
      cor
0.2110061
```

Ici, on ne rejette pas l'hypothèse nulle : les ventes ne semblent pas corrélées au budget publicitaire du même mois (*au seuil de 5%)*.

Exemple (*Investissement publicitaire*)

- Corrélation avec le budget publicitaire du mois précédent :

```r
cor.test(df$`Budget Pub mois précédent ()`,df$`Ventes ()`)
```

```
 Pearson's product-moment correlation

data:  df$`Budget Pub mois précédent ()` and df$`Ventes ()`
t = 10.829, df = 34, p-value = 1.46e-12
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.7765776 0.9377500
sample estimates:
      cor
0.8804748
```

Ici, on rejette l'hypothèse nulle : les ventes sont significativement corrélées avec le budget publicitaire du mois précédent (*au seuil de 5%)*.

2. La régression linéaire simple

2.1 Contexte et exemple

On souhaite dorénavant **expliquer** le lien linéaire pouvant exister entre deux variables X et Y.

On souhaite également **prédire** la valeur de la variable Y en fonction de la variable X.

Exemple (*Engrais et blé*)

- On s'intéresse au lien entre la quantité d'engrais utilisé dans un champ de blé *(en Kg/ha)* et le rendement de ce champ *(en T/ha)*.
- On a ainsi mesuré ces deux quantités dans 50 champs.

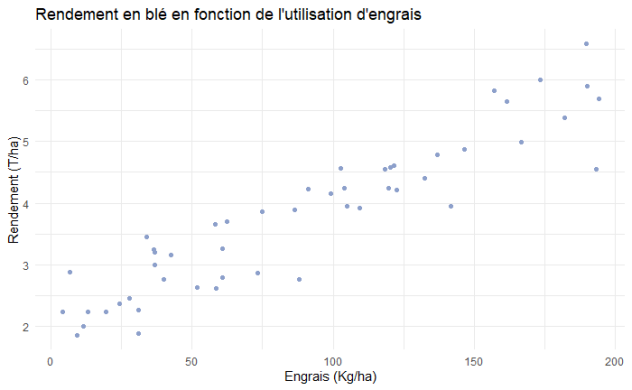

Exemple (*Engrais et blé*)

- Une étude rapide de la corrélation montre un lien linéaire significatif *(au seuil de 5%)* entre ces deux quantités.

```
 Pearson's product-moment correlation

data:  df_wheat$Engrais and df_wheat$Rendement
t = 16.983, df = 48, p-value < 2.2e-16
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.8724140 0.9574931
sample estimates:
      cor
0.9259172
```

- On cherche à expliquer davantage le lien linéaire entre le rendement d'un champ (valeurs y_i) et la quantité d'engrais utilisé (valeurs x_i).

2.2 Modélisation

Modèle linéaire simple

- On suppose dans la suite que les observations $y_1, \ldots, y_n$ s'expliquent en fonction des $x_1, \ldots, x_n$ selon le modèle

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad 1 \leqslant i \leqslant n$$

  où $(\beta_0, \beta_1) \in \mathbb{R}^2$ et les ε_i sont des variables aléatoires, appelées bruits.
- On suppose de plus que les bruits $(\varepsilon_i)_{1 \leqslant i \leqslant n}$:
  - sont indépendants ;
  - sont de même loi $\mathcal{N}(0, \sigma^2)$ avec $\sigma > 0$.

Pour expliquer le lien entre les y_i et les x_i, il faut donc **estimer** les valeurs de β_0, β_1 et σ.

Il s'agit du principe de la **régression linéaire**.

2.3 Moindres Carrés Ordinaires (MCO)

Définition

On appelle **estimateurs des moindres carrés ordinaires**, notés $\hat{\beta}_0$ et $\hat{\beta}_1$, les valeurs de β_0 et β_1 minimisant

$$\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)^2$$

i.e.

$$\left(\hat{\beta}_0, \hat{\beta}_1\right) = \underset{(\beta_0,\beta_1)\in\mathbb{R}^2}{argmin} \sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)^2.$$

Schéma

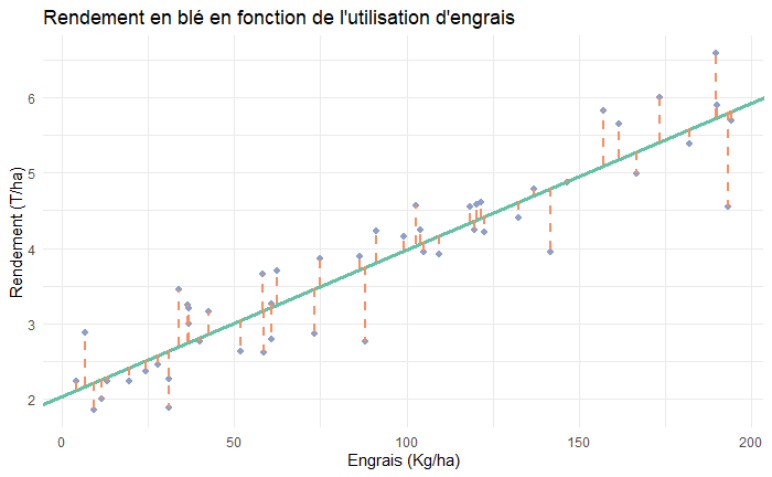

Les estimateurs des MCO définissent la droite minimisant les écarts entre les observations et celle-ci.

Propriété

Les estimateurs des MCO ont pour expressions

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{n}(x_i - \overline{x})^2} \quad \text{et} \quad \hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}.$$

Remarque :

La droite des MCO, donnée par l'équation

$$y = \hat{\beta}_0 + \hat{\beta}_1 x,$$

passe toujours par le centre de gravité $(\overline{x}, \overline{y})$ du nuage de points $((x_i, y_i))_{1 \leqslant i \leqslant n}$.

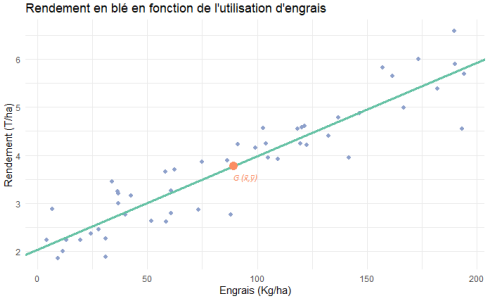

En R, la régression linéaire par les moindres carrés se fait avec la fonction `lm`.

Exemple (*Engrais et blé*)

Reprenons le cas du rendement d'un champ de blé.

```
lm_wheat <- lm(data=df_wheat,formula = Rendement~.)
summary(lm_wheat)
```

```
Residuals:
     Min       1Q   Median       3Q      Max
-1.25014 -0.24539  0.00236  0.34201  0.83999

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.048246   0.121292   16.89   <2e-16 ***
Engrais     0.019442   0.001145   16.98   <2e-16 ***
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.463 on 48 degrees of freedom
Multiple R-squared:  0.8573, Adjusted R-squared:  0.8544
F-statistic: 288.4 on 1 and 48 DF,  p-value: < 2.2e-16
```

Ici, on a $\hat{\beta}_0 \approx 2.05$ et $\hat{\beta}_1 \approx 0.02$.

Lois des estimateurs des MCO

On a

$$\hat{\beta}_1 \sim \mathcal{N}(\beta_1, \sigma_1^2) \quad \text{où} \quad \sigma_1^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \overline{x})^2}$$

et

$$\hat{\beta}_0 \sim \mathcal{N}(\beta_0, \sigma_0^2) \quad \text{où} \quad \sigma_0^2 = \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \right).$$

Remarque :
Les estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$ sont non biaisés.

Théorème (Gauss-Markov)

Les estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$ sont de variance minimale parmi les estimateurs sans biais linéaires en $(y_i)_{1 \leqslant i \leqslant n}$.

Problème :
La valeur de σ^2 est inconnue.

2.4 Résidus

Définition

- Pour toute observation $i \in \{1, \ldots, n\}$, on note

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

  la **valeur ajustée** du modèle en x_i.
- Les **résidus** de la régression sont définis pour tout $i \in \{1, \ldots, n\}$ par

$$\begin{aligned} \hat{\varepsilon}_i &= y_i - \hat{y}_i \\ &= y_i - \left(\hat{\beta}_0 + \hat{\beta}_1 x_i\right). \end{aligned}$$

Remarque

Les résidus correspondent aux erreurs d'ajustement du modèle.

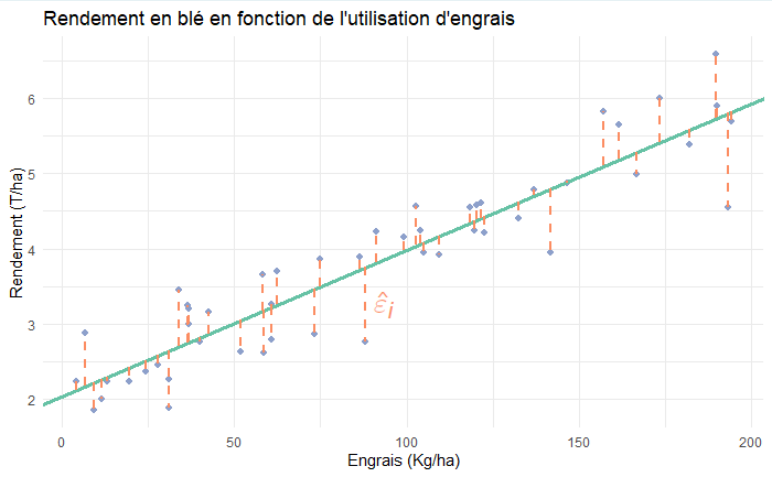

Propriété

On a

$$\sum_{i=1}^{n}(y_i - \overline{y})^2 = \sum_{i=1}^{n}(\hat{y}_i - \overline{y})^2 + \sum_{i=1}^{n}(y_i - \hat{y}_i)^2,$$

ou encore

$$SCT = SCE + SCR.$$

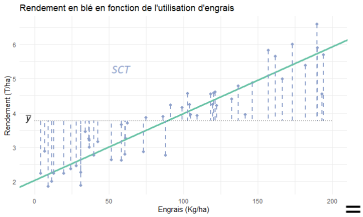

=

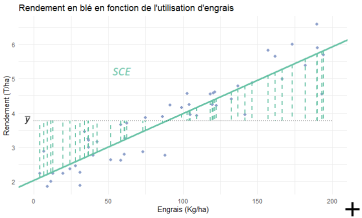

+

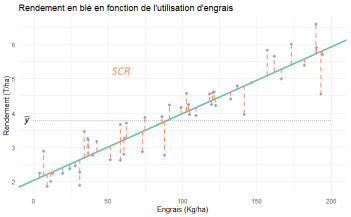

Définition

Le **coefficient de détermination** R^2 du modèle est défini par

$$\begin{aligned} R^2 &= \frac{SCE}{SCT} \\ &= 1 - \frac{SCR}{SCT} \\ &= (\text{Dispersion expliquée par le modèle})/(\text{Dispersion totale}). \end{aligned}$$

Remarques :

- C'est un nombre réel compris entre 0 et 1, représentant la proportion de variance expliquée par le modèle.
- Ce coefficient permet de mesurer l'adéquation du modèle aux données. Plus il est proche de 1, plus le modèle est adapté.

Exemple (*Engrais et blé*)

Dans notre cas, on a $R^2 \approx 0.8573$: la proportion de variance expliquée par le modèle est de 85,73%.

```
lm_wheat <- lm(data=df_wheat,formula = Rendement~.)
summary(lm_wheat)
```

```
Residuals:
     Min       1Q   Median       3Q      Max
-1.25014 -0.24539  0.00236  0.34201  0.83999

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.048246   0.121292   16.89   <2e-16 ***
Engrais     0.019442   0.001145   16.98   <2e-16 ***
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.463 on 48 degrees of freedom
Multiple R-squared:  0.8573, Adjusted R-squared:  0.8544
F-statistic: 288.4 on 1 and 48 DF,  p-value: < 2.2e-16
```

2.5 Lois des estimateurs avec variance estimée

Propriétés

- La statistique $\hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\hat{\varepsilon}_i^2$ est un estimateur non biaisé de σ^2.
- On a $\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-2}$.
- $\hat{\sigma}^2$ est indépendante de $\hat{\beta}_0$ et $\hat{\beta}_1$.

Exemple (*Engrais et blé*)

Dans notre cas, on estime $\hat{\sigma} \approx 0.463$.

```
Residuals:
     Min       1Q   Median       3Q      Max
-1.25014 -0.24539  0.00236  0.34201  0.83999

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.048246   0.121292   16.89   <2e-16 ***
Engrais     0.019442   0.001145   16.98   <2e-16 ***
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.463 on 48 degrees of freedom
Multiple R-squared:  0.8573, Adjusted R-squared:  0.8544
F-statistic: 288.4 on 1 and 48 DF,  p-value: < 2.2e-16
```

Lois des estimateurs avec variance estimée

- On note

$$\hat{\sigma}_1^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \quad \text{et} \quad \hat{\sigma}_0^2 = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{\sum_{i=1}^n (x_i - \overline{x})^2} \right)$$

  les estimateurs de $Var(\hat{\beta}_1)$ et $Var(\hat{\beta}_0)$.

- On a pour $i \in \{0, 1\}$:

$$\frac{\hat{\beta}_i - \beta_i}{\hat{\sigma}_i} \sim \mathcal{T}_{n-2}$$

  où $\mathcal{T}_{n-2}$ désigne la loi de Student à $n - 2$ d.d.l.

Remarque :

Ces propriétés permettent de construire des intervalles de confiance pour β_0, β_1 et σ^2.

Propriétés

- Pour $i \in \{0, 1\}$, un intervalle de confiance pour β_i au niveau $1 - \alpha$ est donné par

$$IC(\beta_i) = \left[\hat{\beta}_i - \hat{\sigma}_i \times t_{n-2}(1 - \alpha/2) \; ; \; \hat{\beta}_i + \hat{\sigma}_i \times t_{n-2}(1 - \alpha/2)\right]$$

  où $t_{n-2}(1 - \alpha/2)$ désigne le quantile d'ordre $(1 - \alpha/2)$ de la loi de Student $\mathcal{T}_{n-2}$.

- Un intervalle de confiance pour σ^2 au niveau $1 - \alpha$ est donné par

$$IC(\sigma^2) = \left[\frac{(n-2)\hat{\sigma}^2}{c_{n-2}(1 - \alpha/2)} \; ; \; \frac{(n-2)\hat{\sigma}^2}{c_{n-2}(\alpha/2)}\right]$$

  où $c_{n-2}(\alpha/2)$ et $c_{n-2}(1 - \alpha/2)$ désignent respectivement les quantiles d'ordres $\alpha/2$ et $(1 - \alpha/2)$ de la loi χ^2_{n-2}.

Exemple (Engrais et blé)

- Dans notre exemple, on a $\hat{\beta}_0 \approx 2.05$ et $\hat{\beta}_1 \approx 0.0194$.

```
lm_wheat <- lm(data=df_wheat,formula = Rendement~.)
lm_wheat$coefficients
```

```
(Intercept)     Engrais
 2.04824563  0.01944231
```

- Des intervalles de confiance de niveau 0.95 pour ces valeurs sont donnés par

$$IC(\beta_0) \approx [1.80\ ;\ 2.29] \quad \text{et} \quad IC(\beta_1) \approx [0.017\ ;\ 0.022].$$

```
confint(lm_wheat,level=0.95)
```

```
                 2.5 %    97.5 %
(Intercept) 1.80437222 2.2921190
Engrais     0.01714052 0.0217441
```

2.6 Nouvelles prévisions

Supposons que l'on ait une nouvelle observation x_{n+1} de la variable explicative X, indépendante des observations $x_1, \ldots, x_n$.

On cherche naturellement à prédire la valeur associée y_{n+1} de la variable Y par

$$\hat{y}_{n+1} = \hat{\beta}_0 + \hat{\beta}_1 x_{n+1}.$$

Question : Comment mesurer l'incertitude sur notre prévision $\hat{y}_{n+1}$?

Propriété

On note toujours ici : $\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$.

- On a

$$\frac{y_{n+1} - \hat{y}_{n+1}}{\sqrt{\hat{\sigma}^2\left(1 + \frac{1}{n} + \frac{(x_{n+1}-\overline{x})^2}{\sum_{i=1}^{n}(x_i-\overline{x})^2}\right)}} \sim \mathcal{T}_{n-2}.$$

- On en déduit un intervalle de confiance de niveau $1-\alpha$ pour y_{n+1}

$$IC(y_{n+1}) = \left[\hat{y}_{n+1} \pm t_{n-2}(1-\alpha/2)\sqrt{\hat{\sigma}^2\left(1 + \frac{1}{n} + \frac{(x_{n+1}-\overline{x})^2}{\sum_{i=1}^{n}(x_i-\overline{x})^2}\right)}\right]$$

où $t_{n-2}(1-\alpha/2)$ désigne le quantile d'ordre $(1-\alpha/2)$ de la loi $\mathcal{T}_{n-2}$.

Exemple (*Engrais et blé*)

- Supposons que dans 3 champs de blés différents, on ait utilisé 75 Kg, 130 Kg et 180 Kg d'engrais par hectare.
- Ci-dessous, on présente les rendements estimés pour ces champs, avec leurs intervalles de confiance au niveau 95%.

```r
new_obs <- data.frame(Engrais = c(75,130,180))
predict(lm_wheat,newdata = new_obs,interval = "prediction")
```

```
       fit      lwr      upr
1 3.506419 2.565659 4.447179
2 4.575746 3.630870 5.520621
3 5.547861 4.584710 6.511012
```

2.7 Nullité des coefficients

Une question statistique d'intérêt :

Les paramètres β_0 et β_1 sont-ils significativement non nuls ?

En effet, même si on a comme estimations $\hat{\beta}_0 \neq 0$ et $\hat{\beta}_1 \neq 0$, il se peut que l'on ait pour les vraies valeurs $\beta_0 = 0$ ou $\beta_1 = 0$.

Remarque : Si $\beta_1 = 0$, cela signifie que la variable X n'explique en fait pas la variable Y (*du moins linéairement...*).

Pour $i \in \{0, 1\}$, on considère le test d'hypothèses :

$$H_0 : \beta_i = 0 \quad \text{contre} \quad H_1 : \beta_i \neq 0.$$

Propriété

- Sous l'hypothèse nulle H_0, on a

$$\frac{\hat{\beta}_i}{\hat{\sigma}_i} \sim \mathcal{T}_{n-2}.$$

- Donc, si $\left|\frac{\hat{\beta}_i}{\hat{\sigma}_i}\right| > t_{n-2}(1 - \alpha/2)$, on rejette H_0 au niveau α.

Exemple (*Engrais et blé*)

Dans notre exemple, on rejette l'hypothèse nulle pour chacune des coefficients. Ceux-ci sont donc significativement non nuls au seuil de 5%.

```
lm_wheat <- lm(data=df_wheat,formula = Rendement~.)
summary(lm_wheat)
```

```
Residuals:
     Min       1Q   Median       3Q      Max 
-1.25014 -0.24539  0.00236  0.34201  0.83999 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 2.048246   0.121292   16.89   <2e-16 ***
Engrais     0.019442   0.001145   16.98   <2e-16 ***
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.463 on 48 degrees of freedom
Multiple R-squared:  0.8573, Adjusted R-squared:  0.8544 
F-statistic: 288.4 on 1 and 48 DF,  p-value: < 2.2e-16
```

3. La régression linéaire multiple

3.1 Contexte et exemple

La modélisation du rendement d'un champ effectuée précédemment est simpliste : d'autres variables peuvent l'expliquer comme la qualité du sol, la température moyenne, etc...

On va chercher à expliquer une variable Y en fonction de plusieurs variables explicatives $X_1, X_2, \ldots, X_p$.

Exemple (*Champs de tomates*)

On a cette fois-ci le rendement de $n = 80$ champs de tomates, supposés indépendants, ainsi que de cinq autres variables explicatives non constantes.

	Y (T/ha)	X1 (Kg/ha)	X2 (mm/ha)	X3 (H/ha)	X4	X5 (°C)
	Rendement	Engrais	Irrigation	Heures_Travail	Qualite_Sol	Temperature
1	3.234626	113.79049	40.01729	52.15813	57.11378	15.23743
2	3.125442	105.39645	41.15584	43.85247	59.97801	16.21811
3	3.337675	176.17417	38.88802	47.21953	79.96061	13.66123
4	3.216521	96.41017	41.93313	54.72312	53.62696	15.66082
5	3.402045	157.58575	39.33854	52.74943	63.20948	14.47709
6	3.151549	119.30130	40.99535	43.89468	84.02362	15.68375

Exemple (*Champs de tomates*)

On représente ci-dessous les corrélations linéaires pouvant exister entre ces variables.

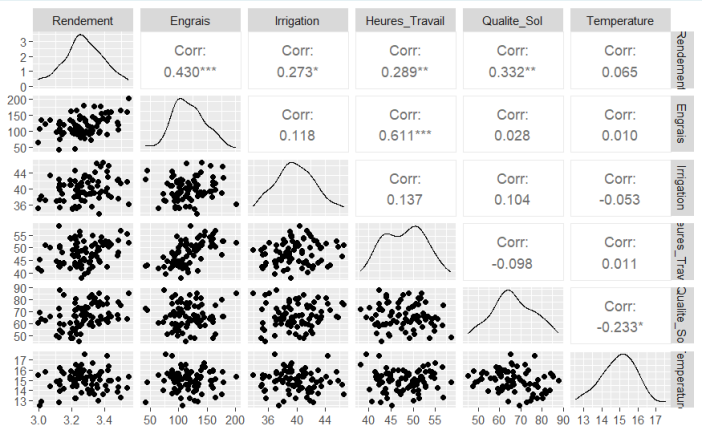

3.2 Modélisation

Notations :

- Y la variable à expliquer : observations $y_1, \ldots, y_n$.
- p le nombre de variables explicatives $X_1, \ldots, X_p$.
- Pour tout $j \in \{1, \ldots, p\}$, les observations de X_j sont :

$$x_{1,j}, x_{2,j}, \ldots, x_{n,j}.$$

- On notera X la matrice de design

$$X = \begin{bmatrix} x_{1,1} & x_{1,2} & \ldots & x_{1,p} \\ x_{2,1} & x_{2,2} & \ldots & x_{2,p} \\ \vdots & \vdots & & \vdots \\ x_{n,1} & x_{n,2} & \ldots & x_{n,p} \end{bmatrix}$$

X1 Engrais	*X2* Irrigation	*X3* Heures_Travail	*X4* Qualite_Sol	*X5* Temperature
113.79049	40.01729	52.15813	57.11378	15.23743
105.39645	41.15584	43.85247	59.97801	16.21811
176.17417	38.88802	47.21953	79.96061	13.66123
96.41017	41.93313	54.72312	53.62696	15.66082
157.58575	39.33854	52.74943	63.20948	14.47709
119.30130	40.99535	43.89468	84.02362	15.68375

supposée de rang p (*aucune variable ne s'écrit linéairement en fonction des autres*).

Modèle linéaire multiple

- On suppose dans la suite que les observations $y_1, \dots, y_n$ s'expliquent selon le modèle

$$y_i = \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p} + \varepsilon_i = \sum_{j=1}^{p} \beta_j x_{i,j} + \varepsilon_i, \quad 1 \leqslant i \leqslant n$$

  où les β_j dont des réels et les ε_i des variables aléatoires (*bruits*).
- On suppose toujours que les bruits $(\varepsilon_i)_{1 \leqslant i \leqslant n}$ sont i.i.d. de loi $\mathcal{N}(0, \sigma^2)$, où $\sigma > 0$.

Remarque

On a en fait

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} x_{1,1} & x_{1,2} & \dots & x_{1,p} \\ x_{2,1} & x_{2,2} & \dots & x_{2,p} \\ \vdots & \vdots & & \vdots \\ x_{n,1} & x_{n,2} & \dots & x_{n,p} \end{bmatrix} \cdot \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

ce qui s'écrit $Y = X \cdot \beta + \varepsilon$, où $\varepsilon \sim \mathcal{N}_{\mathbb{R}^n}(0, \sigma^2 I_n)$.

Remarque

- Dans la plupart des cas, l'équation de la régression contient une constante, correspondant au cas où la variable X_1 est constante et égale à 1 ($x_{i,1} = 1$ *pour tout i)*.
  On a alors
  $$y_i = \beta_1 + \beta_2 x_{i,2} + \cdots + \beta_p x_{i,p} + \varepsilon_i.$$
- La matrice de design s'écrit alors

$$X = \begin{bmatrix} 1 & x_{1,2} & \dots & x_{1,p} \\ 1 & x_{2,2} & \dots & x_{2,p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n,2} & \dots & x_{n,p} \end{bmatrix}$$

3.3 Moindres Carrés Ordinaires (MCO)

Définition

On appelle **estimateur des moindres carrés ordinaires**, noté $\hat{\beta} \in \mathbb{R}^p$

$$\begin{aligned}\hat{\beta} &= \underset{\beta \in \mathbb{R}^p}{argmin} \sum_{i=1}^{n} \left(y_i - \sum_{j=1}^{p} \beta_j x_{i,j} \right)^2 \\ &= \underset{\beta \in \mathbb{R}^p}{argmin} \, \| Y - X\beta \|^2.\end{aligned}$$

Remarque : Déterminer

$$\hat{\beta} = \underset{\beta \in \mathbb{R}^p}{argmin} \, \|Y - X\beta\|^2$$

revient à déterminer le projeté orthogonal de Y sur $F = Vect(X_1, \ldots, X_p)$, le sous espace de dimension p de R^n engendré par les vecteurs colonnes de X.

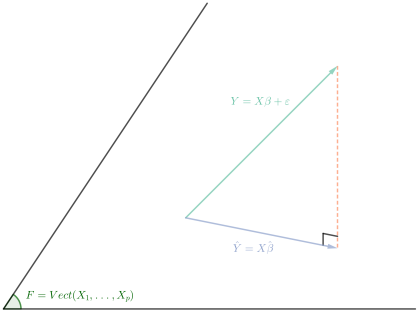

Propriété

L'estimateur des MCO a pour expression

$$\hat{\beta} = \left(X^T X\right)^{-1} X^T Y.$$

Exemple (*Champs de tomates*)

Dans notre exemple, où l'on cherche à expliquer le rendement *(observations y_i)* en fonction des autres variables, on a :

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais        0.0013818  0.0004776   2.894 0.005001 **
Irrigation     0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail 0.0021900  0.0031519   0.695 0.489337
Qualite_Sol    0.0041781  0.0011842   3.528 0.000723 ***
Temperature    0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

Loi des estimateurs des MCO

- On a
$$\hat{\beta} \sim \mathcal{N}_{\mathbb{R}^p}\left(\beta, \sigma^2 \left(X^T X\right)^{-1}\right).$$
- En particulier, pour tout $j \in \{1, \ldots, p\}$
$$\hat{\beta}_j \sim \mathcal{N}\left(\beta_j, \sigma^2 \left(X^T X\right)^{-1}_{jj}\right).$$

Remarque : L'estimateur $\hat{\beta}$ est donc non biaisé.

Problème : La valeur de σ^2 est inconnue.

3.4 Résidus

Définition

- Le vecteur des **valeurs ajustées** du modèle est donné par

$$\hat{Y} = X \cdot \hat{\beta} \in \mathbb{R}^n$$

  On a en fait $\hat{Y} = (\hat{y}_1, \ldots, \hat{y}_n)^T$ où $\hat{y}_i = \sum_{j=1}^{p} \hat{\beta}_j x_{i,j}, \quad 1 \leqslant i \leqslant n.$

- Le vecteur des **résidus** est donné par

$$\hat{\varepsilon} = Y - \hat{Y}.$$

  On a en fait $\hat{\varepsilon} = (\hat{\varepsilon}_1, \ldots, \hat{\varepsilon}_n)^T$ où $\hat{\varepsilon}_i = y_i - \hat{y}_i, \quad 1 \leqslant i \leqslant n.$

Remarque :

Par définition, le projeté orthogonal de Y sur $F = Vect(X_1, \ldots, X_p)$ est donné par $\hat{Y} = X\hat{\beta}$.

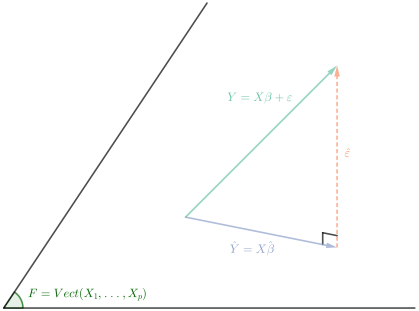

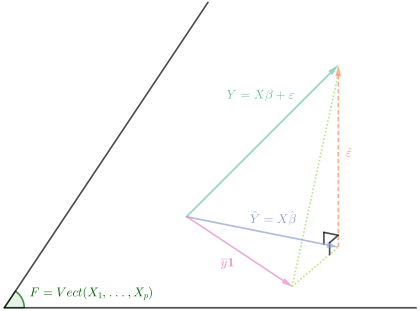

La constante ne fait pas partie du modèle *(X_1 n'est pas constante et égale à 1)*.
Les vecteurs $\hat{Y}$ et $\hat{\varepsilon}$ sont orthogonaux :

$$\|Y\|^2 = \|\hat{Y}\|^2 + \|\hat{\varepsilon}\|^2.$$

La constante fait partie du modèle *($X_1 = (1, \ldots, 1)^T = \mathbb{1}$)*.
Les vecteurs $\hat{Y} - \overline{y}\mathbb{1}$ et $\hat{\varepsilon}$ sont orthogonaux :

$$\|Y - \overline{y}\mathbb{1}\|^2 = \|\hat{Y} - \overline{y}\mathbb{1}\|^2 + \|\hat{\varepsilon}\|^2.$$

Dans les deux cas, on note $SCT = SCE + SCR$.

Définition

Le **coefficient de détermination** R^2 est défini par

$$R^2 = (\text{Dispersion expliquée par le modèle})/(\text{Dispersion totale}) = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

- Si la constante ne fait pas partie du modèle :

$$R^2 = \frac{\|\hat{Y}\|^2}{\|Y\|^2} = 1 - \frac{\|\hat{\varepsilon}\|^2}{\|Y^2\|}.$$

- Si la constante fait partie du modèle :

$$R^2 = \frac{\|\hat{Y} - \overline{y}\mathbb{1}\|^2}{\|Y - \overline{y}\mathbb{1}\|^2} = 1 - \frac{\|\hat{\varepsilon}\|^2}{\|Y - \overline{y}\mathbb{1}\|^2}.$$

Remarque : Il s'agit toujours d'un nombre réel compris entre 0 et 1, donnant la proportion de variance expliquée par le modèle. Plus il est proche de 1, plus le modèle est adapté aux données.

Exemple (*Champs de tomates*)

Le modèle linéaire explique environ 35% de la variance dans notre étude sur le rendement des champs de tomates.

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais        0.0013818  0.0004776   2.894 0.005001 **
Irrigation     0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail 0.0021900  0.0031519   0.695 0.489337
Qualite_Sol    0.0041781  0.0011842   3.528 0.000723 ***
Temperature    0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

Remarque :

Plus il y a de variables à expliquer la variable réponse, plus le R^2 sera proche de 1.

Afin de tenir compte de la dimension de l'espace de projection, on peut considérer la définition suivante.

Définition

Le **coefficient de détermination ajusté**, noté R_a^2 est défini par :

- $R_a^2 = 1 - \frac{n}{n-p} \times \frac{\|\hat{\varepsilon}\|^2}{\|Y\|^2} = 1 - \frac{n}{n-p}(1 - R^2)$ si la constante ne fait pas partie du modèle.
- $R_a^2 = 1 - \frac{n-1}{n-p} \times \frac{\|\hat{\varepsilon}\|^2}{\|Y - \overline{y}\mathbb{1}\|^2} = 1 - \frac{n-1}{n-p}(1 - R^2)$ si la constante fait partie du modèle.

Exemple (*Champs de tomates*)

Le coefficient de détermination ajusté est d'environ 0.306 dans notre modèle.

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais        0.0013818  0.0004776   2.894 0.005001 **
Irrigation     0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail 0.0021900  0.0031519   0.695 0.489337
Qualite_Sol    0.0041781  0.0011842   3.528 0.000723 ***
Temperature    0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

3.5 Lois des estimateurs avec variance estimée

Propriétés

- La statistique $\hat{\sigma}^2 = \dfrac{1}{n-p}\|\hat{\varepsilon}\|^2 = \dfrac{1}{n-p}\sum_{i=1}^{n}\hat{\varepsilon}_i^2$ est un estimateur non baisé de σ^2.
- On a $\dfrac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-p}$.
- $\hat{\sigma}^2$ est indépendante de $\hat{\beta}$.

Exemple (*Champs de tomates*)

Dans notre cas, on estime $\hat{\sigma} \approx 0.1016$.

```
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)     2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais         0.0013818  0.0004776   2.894 0.005001 **
Irrigation      0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail  0.0021900  0.0031519   0.695 0.489337
Qualite_Sol     0.0041781  0.0011842   3.528 0.000723 ***
Temperature     0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

Lois des estimateurs avec variance estimée

On rappelle que pour tout $j \in \{1, \ldots, p\}$

$$\hat{\beta}_j \sim \mathcal{N}\left(0, \sigma^2 \left(X^T X\right)^{-1}_{jj}\right).$$

On note alors $\hat{\sigma}_j^2 = \hat{\sigma}^2 \left(X^T X\right)^{-1}_{jj}$, et on a

$$\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}_j} \sim \mathcal{T}_{n-p}$$

où $\mathcal{T}_{n-p}$ désigne la loi de Student à $n - p$ d.d.l.

Remarque :
Ces propriétés permettent de construire des intervalles de confiance pour les β_j et σ^2.

Propriétés

- Pour tout $j \in \{1, \ldots, p\}$, un intervalle de confiance pour β_j au niveau $1 - \alpha$ est donné par

$$IC(\beta_j) = \left[\hat{\beta}_j - \hat{\sigma}_j \times t_{n-p}(1 - \alpha/2) \; ; \; \hat{\beta}_j + \hat{\sigma}_j \times t_{n-p}(1 - \alpha/2)\right]$$

  où $t_{n-p}(1 - \alpha/2)$ désigne le quantile d'ordre $(1 - \alpha/2)$ de la loi de Student $\mathcal{T}_{n-p}$.

- Un intervalle de confiance pour σ^2 au niveau $1 - \alpha$ est donné par

$$IC(\sigma^2) = \left[\frac{(n-p)\hat{\sigma}^2}{c_{n-p}(1 - \alpha/2)} \; ; \; \frac{(n-p)\hat{\sigma}^2}{c_{n-p}(\alpha/2)}\right]$$

  où $c_{n-p}(\alpha/2)$ et $c_{n-p}(1 - \alpha/2)$ désignent respectivement les quantiles d'ordres $\alpha/2$ et $(1 - \alpha/2)$ de la loi χ^2_{n-p}.

Exemple (*Champs de tomates*)

On obtient ces intervalles de confiance pour les coefficients dans notre modèle avec la fonction `confint` de R.

```r
lm_tomato <- lm(data = df_tomato,formula = Rendement ~.)
confint(lm_tomato)
```

```
                       2.5 %      97.5 %
(Intercept)     1.5589695200 2.697747984
Engrais         0.0004302768 0.002333366
Irrigation      0.0001128166 0.016432983
Heures_Travail -0.0040902134 0.008470244
Qualite_Sol     0.0018185737 0.006537700
Temperature    -0.0049447805 0.041023670
```

3.6 Nouvelles prévisions

Supposons que l'on ait une nouvelle observation $x_{n+1} = (x_{n+1,1}, \ldots, x_{n+1,p})$, indépendante des observations $x_1, \ldots, x_n$.

On prédit naturellement la valeur associée y_{n+1} de la variable réponse Y par

$$\hat{y}_{n+1} = \sum_{j=1}^{p} \hat{\beta}_j x_{n+1,j} = x_{n+1} \cdot \hat{\beta}.$$

Question : Comment mesure l'incertitude sur la prévision $\hat{y}_{n+1}$?

Propriété

- On a

$$\frac{y_{n+1} - \hat{y}_{n+1}}{\sqrt{\hat{\sigma}^2 \left(1 + x_{n+1} \left(X^T X\right)^{-1} x_{n+1}^T\right)}} \sim \mathcal{T}_{n-p}.$$

- On en déduit un intervalle de confiance de niveau $1 - \alpha$ pour y_{n+1}

$$IC(y_{n+1} = \left[\hat{y}_{n+1} \pm t_{n-p}(1 - \alpha/2)\sqrt{\hat{\sigma}^2 \left(1 + x_{n+1} \left(X^T X\right)^{-1} x_{n+1}^T\right)}\right]$$

où $t_{n-p}(1 - \alpha/2)$ désigne le quantile d'ordre $(1 - \alpha/2)$ de la loi $\mathcal{T}_{n-p}$.

Exemple (*Champs de tomates*)

- Supposons que l'on dispose des 3 champs différents suivants.

```
new_obs <- data.frame(Engrais = c(70,100,150),
                      Irrigation = c(35,40,45),
                      Heures_Travail = c(40,50,45),
                      Qualite_Sol = c(80,60,75),
                      Temperature = c(15,13,16))
```

```
  Engrais Irrigation Heures_Travail Qualite_Sol Temperature
1      70         35             40          80          15
2     100         40             50          60          13
3     150         45             45          75          16
```

- On obtient les rendements estimés pour ces champs, avec leurs intervalles de confiance au niveau 95%

```
predict(lm_tomato,newdata = new_obs,interval = "prediction")
```

```
       fit      lwr      upr
1 6.813248 6.302925 7.323571
2 6.737884 6.200317 7.275452
3 7.115340 6.604831 7.625849
```

3.7 Nullité des coefficients

Question statistique d'intérêt : Les coefficients $(\beta_j)_{1 \leqslant j \leqslant p}$ sont-il significativement non nuls ?

En effet, même si on a $\hat{\beta}_j \neq 0$ pour un certain $j \in \{1, \ldots, p\}$, il se peut que la vraie valeur vérifie $\beta_i = 0$.

Remarques :

- Si $\beta_j = 0$, cela signifie que la variable X_j n'explique pas *(linéairement)* la variable Y.
- On peut tester si un ou plusieurs coefficients son simultanément nuls.

Nullité d'un coefficient

Pour $j \in \{1, \ldots, p\}$, on considère le test d'hypothèses :

$$H_0 : \beta_j = 0 \quad \text{contre } H_1 : \beta_j \neq 0.$$

Propriété

Sous l'hypothèse nulle H_0, on a

$$\frac{\hat{\beta}_j}{\hat{\sigma}_j} \sim \mathcal{T}_{n-p}.$$

Donc, si $\left|\frac{\hat{\beta}_j}{\hat{\sigma}_j}\right| > t_{n-p}(1 - \alpha/2)$, on rejette H_0 au niveau α.

Exemple (*Champs de tomates*)

- Dans notre exemple, on ne rejette pas, au seuil de 5%, l'hypothèse $\beta_6 = 0$. En l'occurrence, la température ne semble pas jouer de rôle significatif dans notre modèle.
- En revanche, on rejette l'hypothèse $\beta_3 = 0$. L'impact de l'irrigation est donc siginificativement non nul, au seuil de 5%.

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais        0.0013818  0.0004776   2.894 0.005001 **
Irrigation     0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail 0.0021900  0.0031519   0.695 0.489337
Qualite_Sol    0.0041781  0.0011842   3.528 0.000723 ***
Temperature    0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

Remarques :

- Dans l'exemple précédent, si on souhaite par exemple tester

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{contre} \quad H_1 : \exists j \in \{1, 2, 3\},\ \beta_j \neq 0,$$

  utiliser les statistiques de test précédentes n'est pas très pertinent...
- En effet, si on prend comme zone de rejet

$$\mathcal{R} = \bigcup_{j=1}^{3} \left\{ \left| \frac{\hat{\beta}_j}{\hat{\sigma}_j} \right| > t_{n-p}(1 - \alpha/2) \right\},$$

  le risque de 1ère espèce n'est pas nécessairement majoré par α (*il est majoré par* 3α).
- « Plus on cherche un coefficient significatif, plus on a de chances de trouver... »
- On peut appliquer un critère de correction (*Bonferoni par exemple*)...
- ... ou utiliser une zone de rejet beaucoup plus restrictive comme simplement

$$\mathcal{R}' = \left\{ \left| \frac{\hat{\beta}_1}{\hat{\sigma}_1} \right| > t_{n-p}(1 - \alpha/2) \right\},$$

  mais la puissance du test est alors faible.

Exemple (*Champs de tomates*)

Dans notre exemple, on peut tester

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_5 = 0 \quad \text{contre} \quad H_1 : \exists j \in \{1, 2, 3, 5\},\ \beta_j \neq 0.$$

Si on additionne les *p*-values

$$1.42\mathrm{e}^{-10} + 0.005001 + 0.0046994 + 0.000723 \leqslant 0.052718,$$

On ne garantit plus un risque de 1ère espèce inférieur à 5%.

```
Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)     2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais         0.0013818  0.0004776   2.894 0.005001 **
Irrigation      0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail  0.0021900  0.0031519   0.695 0.489337
Qualite_Sol     0.0041781  0.0011842   3.528 0.000723 ***
Temperature     0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

« Plus on cherche, plus on a de chances de trouver... »

Nullité simultanée de plusieurs coefficients

On veut tester la nullité simultanée des $q = p - p_0$ derniers coefficients du modèle :

$$H_0 : \beta_{p_0+1} = \cdots = \beta_p = 0 \quad \text{contre} \quad H_1 : \exists j \in \{p_0 + 1, \ldots, p\},\ \beta_j \neq 0.$$

On note $\hat{Y}_0$ le vecteur des valeurs ajustées du modèle en ne gardant que les p_0 premières variables, et $\hat{\varepsilon}_0$ le vecteur des résidus associés.

Propriété

Sous H_0, on a

$$F = \frac{n-p}{q} \times \frac{\|\hat{Y} - \hat{Y}_0\|^2}{\|Y - \hat{Y}\|^2} = \frac{n-p}{q} \times \frac{SCR_0 - SCR}{SCR} \sim \mathcal{F}^q_{n-p}$$

où :

- SCR_0 est la somme des carrés résiduels en ne prenant que les p_0 premières variables ;
- $\mathcal{F}^q_{n-p}$ désigne la loi de Fisher à q et $n - p$ d.d.l.

Donc, si $F > f^q_{n-p}(1 - \alpha)$, le quantile d'ordre $(1 - \alpha)$ de la loi $\mathcal{F}^q_{n-p}$, on rejette H_0 au niveau α.

Remarque :

L'idée du test est de considérer que si $\hat{Y}_0$ est proche de $\hat{Y}$, alors il semble raisonnable de conserver l'hypothèse nulle, car les q dernières variables n'apportent pas grand chose.

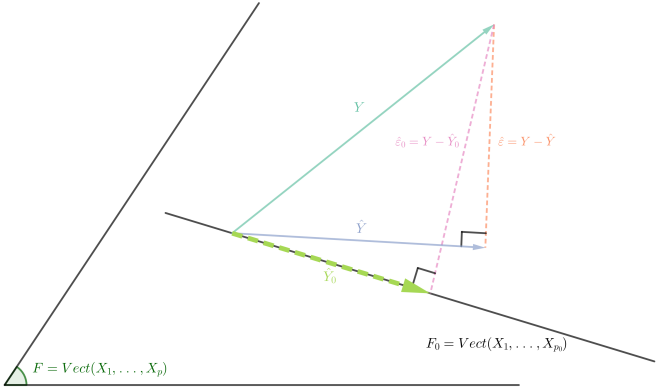

Exemple (*Champs de tomates*)

Dans R, on peut utiliser la fonction `anova` pour effectuer un tel test. On cherche ci-dessous à tester simultanément la significativité des coefficients β_4 et β_5, associés aux variables `Heures_Travail` et `Qualite_Sol`.

```r
# Modèle complet
lm_complet <- lm(data = df_tomato,formula = Rendement ~.)
# Modèle réduit
lm_reduit <- lm (data=df_tomato,formula = Rendement ~ Engrais + Irrigation + Temperature)
# Test
anova(lm_complet,lm_reduit)
```

```
Model 1: Rendement ~ Engrais + Irrigation + Heures_Travail + Qualite_Sol +
    Temperature
Model 2: Rendement ~ Engrais + Irrigation + Temperature
  Res.Df     RSS Df Sum of Sq      F   Pr(>F)
1     74 0.76409
2     76 0.89284 -2  -0.12875 6.2347 0.003145 **
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1
```

Ici, on rejette H_0.

⚙ **Remarque :** Ce test, appelé **test entre modèles emboîtés**, est en fait équivalent au test de rapport de vraisemblance maximale.

Cas particulier : test de Fisher global

On peut vouloir tester si tous les coefficients sont nuls, exceptée la constante. Dans ce cas, $\hat{Y}_0 = \overline{y}\mathbb{1}$ et on a comme statistique de test

$$F = \frac{n-p}{p-1} \times \frac{\|\hat{Y} - \hat{Y}_0\|^2}{\|Y - \hat{Y}\|^2} = \frac{n-p}{p-1} \times \frac{R^2}{1-R^2} \sim \mathcal{F}_{n-p}^{p-1}.$$

⚙ **Remarque :** S'il n'y a qu'une seule variable en dehors de la constante, ce test est alors équivalent au test de Student vu pour la régression linéaire simple.

Exemple (*Champs de tomates*)

Dans le cas du test de Fisher global, le résultat est immédiatement fourni par la fonction `summary` de R.

```
Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    2.1283588  0.2857600   7.448 1.42e-10 ***
Engrais        0.0013818  0.0004776   2.894 0.005001 **
Irrigation     0.0082729  0.0040953   2.020 0.046994 *
Heures_Travail 0.0021900  0.0031519   0.695 0.489337
Qualite_Sol    0.0041781  0.0011842   3.528 0.000723 ***
Temperature    0.0180394  0.0115351   1.564 0.122114
---
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1   1

Residual standard error: 0.1016 on 74 degrees of freedom
Multiple R-squared:  0.3499, Adjusted R-squared:  0.306
F-statistic: 7.965 on 5 and 74 DF,  p-value: 4.767e-06
```

Ici, on rejette au niveau 5% l'hypothèse comme quoi tous les coefficients seraient nuls en dehors de la constante.

4. Validation du modèle

On a proposé jusqu'alors d'expliquer la variable réponse Y en fonction des p variables explicatives $X = (X_1, \ldots, X_p)^T$ par

$$Y = X \cdot \beta + \varepsilon$$

où $\beta = (\beta_1, \ldots, \beta_p)^T$ et $\varepsilon \sim \mathcal{N}_{\mathbb{R}^n}(0, \sigma^2 I_n)$.

On cherche à présent un moyen de valider, ou de refuser, le modèle proposé.

Dans cette section, on va proposer quelques pistes intuitives afin de répondre à cette question.

4.1 Analyse des résidus

L'idée première est de regarder les résidus :

- ils correspondent à la partie non expliquée par le modèle ;
- les hypothèses principales du modèle sont faites sur le bruit ε, approché par les résidus $\hat{\varepsilon}$.

Résidus et valeurs aberrantes

Notons $H = X\left(X^T X\right)^{-1} X^T$ la matrice de projection orthogonale sur $Vect(X_1, \ldots, X_p)$. On rappelle que les valeurs ajustées du modèle sont données par

$$\hat{Y} = H \cdot Y.$$

On peut montrer que pour chaque $i \in \{1, \ldots, n\}$

$$\hat{\varepsilon} \sim \mathcal{N}(0, \sigma^2(1 - H_{ii})).$$

Les résidus n'ont pas tous la même distribution *(celle-ci dépend de i)*.

Afin d'éliminer cette hétérogénéité, on pourrait considérer les **résidus normalisés**

$$r_i = \frac{\varepsilon_i}{\sigma\sqrt{1 - H_{ii}}},$$

mais σ est inconnu.

On remplace naturellement σ par son estimateur $\hat{\sigma}$, et on obtient les **résidus standardisés**

$$s_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}\sqrt{1 - H_{ii}}},$$

mais la loi des s_i est alors inconnue.

On prend en fin de compte les **résidus studentisés**

$$t_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{-i}\sqrt{1 - H_{ii}}}$$

où $\hat{\sigma}_{-i}$ correspond à l'estimateur de σ dans le modèle privé de l'observation i.

Propriété

Si la suppression de la ligne i ne modifie pas le rang de X, alors les résidus studentisés vérifient

$$t_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}_{-i}\sqrt{1 - H_{ii}}} \sim \mathcal{T}_{n-p-1}.$$

Définition

Une **donnée aberrante** est un point (x_i, y_i) pour lequel le résidu studentisé vérifie

$$|t_i| > t_{n-p-1}(1-\alpha/2)$$

où $t_{n-p-1}(1-\alpha/2)$ est le quantile d'ordre $(1-\alpha/2)$ de la loi $\mathcal{T}_{n-p-1}$.

Remarques :

- Une donnée aberrante est une donnée mal expliquée par le modèle, conduisant à un résidu studentisé élevé.
- En pratique, si $\alpha = 0.05$ et $n-p-1 \geqslant 30$, on a $t_{n-p-1}(1-\alpha/2) \approx 2$.

Exemple (*Champs de tomates*)

Dans notre exemple de rendement d'un champ de tomates, on récupère les résidus studentisés et le quantile $t_{n-p-1}(1-\alpha/2)$:

```
stud_res <- rstudent(lm_tomato) # Résidus studentisés
t <- qt(p=0.975,df=n-5-1) # Quantile d'ordre (1-alpha/2)
```

On peut ensuite représenter les résidus studentisés :

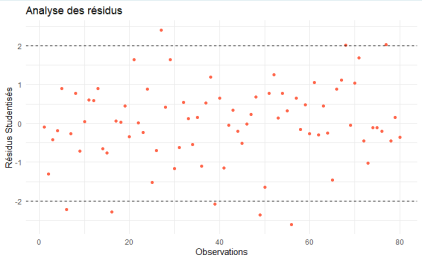

Ici, on compte 8 données aberrantes sur 80. On dépasse le seuil critique de 5% des données, ce qui laisse à penser que le modèle n'est peut être pas très bon...

Analyse de la normalité

L'hypothèse de normalité du bruit

$$\varepsilon \sim \mathcal{N}_{\mathbb{R}^n}(0, \sigma^2 I_n)$$

est difficile à vérifier.

Néanmoins, si $n \gg p$, la loi $\mathcal{T}_{n-p-1}$ suivie par les résidus studentisés t_i est très proche d'une loi normale $\mathcal{N}(0, 1)$.

L'aspect « quasi-gaussien » des résidus studentisés peut alors être évalué graphiquement

- par un histogramme ;
- par un diagramme quantile-quantile *(ou Q-Q plot)*.

Exemple (*Champs de tomates*)

Le *Q-Q plot* des résidus studentisés peut être obtenu avec la fonction `qqnorm` de R :

```
qqnorm(y=stud_res,xlab = "Quantiles Théoriques",ylab="Quantiles Empiriques",
       main="Q-Q Plot des résidus studentisés") # Q-Q Plot
abline(a=0,b=1,col="tomato") # Droite d'équation y=x
```

Si le nuage de points est proche de la droite d'équation $y = x$, l'hypothèse de normalité des résidus peut être considérée comme valide.

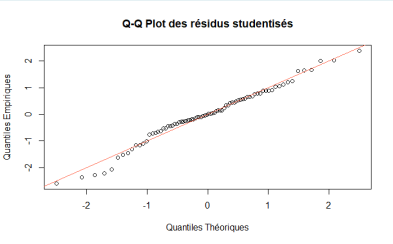

Ici, le diagramme est plutôt satisfaisant, excepté pour les quantiles les plus bas. On a en fait un peu trop de résidus studentisés « trop bas ».

Analyse de l'homoscédasticité

On cherche ici à vérifier si les résidus ont effectivement tous la même variance.

S'il n'existe pas de procédure précise pour vérifier cette hypothèse, une procédure courante est de tracer le nuage de points $(\hat{y}_i, t_i)_{1 \leqslant i \leqslant n}$.

Si une structure apparaît *(tendance, cône, ou vagues...)* l'hypothèse d'homoscédasticité risque de ne pas être vérifiée.

Remarque : Dans un tel cas, il est d'ailleurs fort possible qu'une variable explicative n'ait pas été ajoutée au modèle, ou que le modèle ne soit en fait pas linéaire...

Quelques exemples où une structure apparaît :

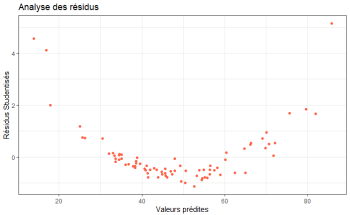

Structure quadratique

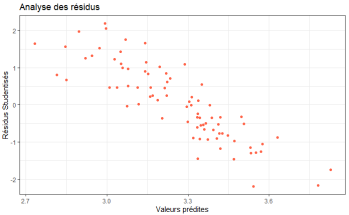

Structure linéaire

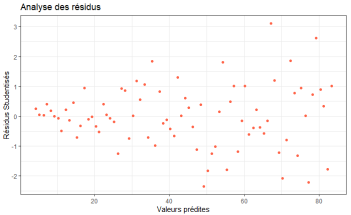

Cône de dispersion

Remarques :

- Selon la nature du problème étudié, d'autres choix que les valeurs ajustées $\hat{y}_i$ peuvent être faits pour l'axe des abscisses *(cela peut être l'indice i, une autre variable spatiale ou temporelle, etc..)*.
- De tels graphiques peuvent également remettre en question l'hypothèse d'indépendance des observations.

Exemple (*Champs de tomates*)

Dans notre exemple, aucune structure n'apparaît, laissant penser que l'hypothèse d'homoscédasticité est vérifiée.

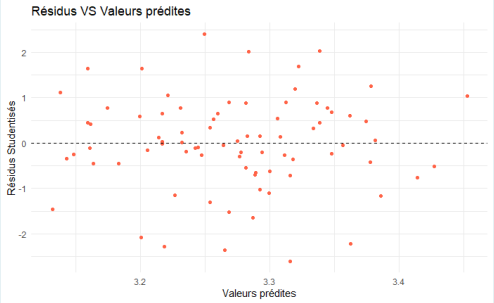

En conclusion, le bilan de notre modèle est mitigé : si les hypothèses de normalité et d'homoscédasticité semblent vérifiées, nous avions ici un peu trop de valeurs aberrantes.

4.2 Importance des observations

On souhaite à présent évaluer le poids de chaque observation dans l'inférence du modèle.

Quel est le poids d'une observation (x_i, y_i) sur sa propre prévision $\hat{y}_i$?

Quel est le poids d'une observation (x_i, y_i) sur l'estimation du paramètre $\beta = (\beta_1, \ldots, \beta_p)^T$ du modèle ?

Points leviers

On note toujours $H = X\left(X^T X\right)^{-1} X^T$ la matrice de projection sur $Vect(X_1, \ldots, X_p)$.

Propriété

Pour toute observation i, la valeur ajustée $\hat{y}_i$ vérifie

$$\hat{y}_i = H_{ii} y_i + \sum_{j \neq i} H_{ij} y_j.$$

Ainsi, H_{ii} est une mesure du poids de l'observation i sur sa propre prévision.

H étant une matrice de projection, on a $Tr(H) = p$, i.e.

$$\sum_{i=1}^{n} H_{ii} = p.$$

La valeur moyenne des H_{ii} est donc égale à p/n, ce qui permet de déterminer si le poids d'une observation H_{ii} est particulièrement grand.

Définition

Une observation (x_i, y_i) est un **point levier** si :

- $H_{ii} > \frac{2p}{n}$ au sens de Hoaglin et Welsch *(1978)* ;
- $H_{ii} > \frac{3p}{n}$ au sens de Velleman et Welsch *(1981)* ;
- $H_{ii} > 0.5$ au sens de Huber *(1981)*.

Exemple (*pâtes à tartiner*)

On a mesuré, sur un échantillon de 60 pâtes à tartine, les teneurs en Lipides (en g/100g de produit) ainsi que l'énergie (en Kcal pour 100g de produit).

On a représenté ci-dessous le nuage de points représentant cet échantillon ainsi que la droite de régression obtenue par les MCO.

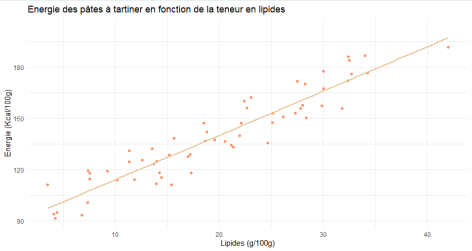

Les valeurs H_{ii} de la matrice de projection s'obtiennent via la commande suivante en R.

```
hatvalues(lm_cal) # lm_cal est le modèle linéaire ajusté sur les données
```

Exemple (*pâtes à tartiner*)

Les poids H_{ii} peuvent ensuite être représentés par un diagramme en barres.

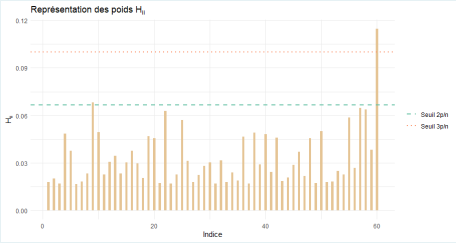

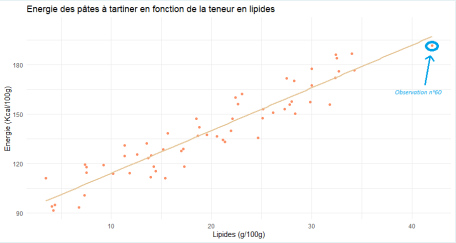

Ici, on trouve un ou deux points leviers selon le critère choisi, et la 60ème observation ne fait pas le moindre doute : elle a donc un poids particulièrement grand dans sa prévision.

Cette observation est un point levier de par son éloignement par rapport au centre de gravité du nuage de points. Elle ne semble cependant pas aberrante, car elle est bien expliquée par la droite de régression.

Il s'agit en fait d'une pâte à tartiner beaucoup plus grasse que les autres produits.

Distance de Cook

On cherche ici à mesurer l'influence d'une observation sur l'estimation du paramètre β.

On peut montrer que

$$\left\{\beta \in \mathbb{R}^p \ : \ \frac{1}{p\hat{\sigma}^2}(\hat{\beta}-\beta)^T(X^TX)(\hat{\beta}-\beta) \leqslant f^p_{n-p}(1-\alpha)\right\},$$

où $f^p_{n-p}(1-\alpha)$ est le quantile d'ordre $(1-\alpha)$ de la loi de Fisher $\mathcal{F}^p_{n-p}$, est une région de confiance de niveau $1-\alpha$ pour le paramètre β.

On va se servir de cette propriété pour construire une distance permettant de mesurer l'impact d'une observation sur l'estimation de β.

Définition

La **distance de Cook** pour la $i^{\text{ème}}$ observation est défini par

$$C_i = \frac{1}{p\hat{\sigma}^2}(\hat{\beta}_{-i} - \hat{\beta})^T (X^T X)(\hat{\beta}_{-i} - \hat{\beta})$$

où $\hat{\beta}_{-i}$ correspond à l'estimation de β dans le modèle privé de l'observation i.

Remarques :

- On fait ici un abus de langage, car il s'agit en fait du carré d'une distance.
- La distance de Cook permet de définir une observation influente. Il s'agit d'une observation qui, enlevée du modèle, conduit à une variation importante de l'estimation du paramètre β.
- Plus C_i est grande, plus la $i^{\text{ème}}$ observation est influente.

Plus la distance de Cook C_i est grande, plus la $i^{\text{ème}}$ observation est influente...

... voire trop !

On utilise en pratique les seuils suivants.

- Ne pas dépasser le seuil $f^p_{n-p}(0.1)$ est souhaitable.
- Dépasser le seuil $f^p_{n-p}(0.5)$ est jugé préoccupant.
- Les deux premiers seuils étant assez permissifs, on prend souvent le seuil $4/n$.

Remarque : On peut montrer que

$$C_i = \frac{H_{ii}}{p(1 - H_{ii})} \times t_i^2$$

où t_i est le résidu studentisé de la $i^{\text{ème}}$ observation.

La distance de Cook peut donc être vue comme la contribution de deux termes.

- Un terme $H_{ii}/(1 - H_{ii})$, qui grandit lorsque le poids H_{ii} *(compris entre 0 et 1)* grandit.
- Un terme t_i^2 qui mesure si la donnée est aberrante.

Exemple (*pâtes à tartiner*)

On récupère les distances de Cook dans notre exemple de pâtes à tartiner.

```
cook <- cooks.distance(lm_cal) # lm_cal est le modèle linéaire ajusté sur les données
```

On peut ensuite les représenter par un diagramme en barres.

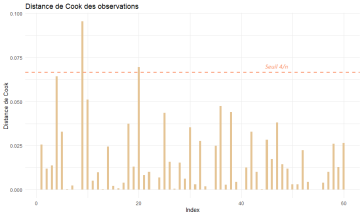

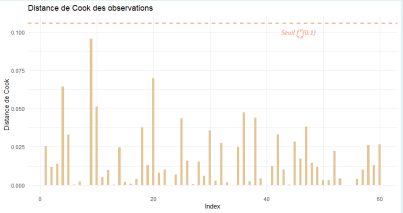

Ici, deux observations possèdent une distance de Cook élevée, mais aucune n'est réellement influente, et encore moins préoccupante. Il s'agit en fait simplement d'observations mal expliquées par le modèle, avec des résidus élevés.

Dans tous les cas, il est souhaitable regarder un peu plus en détails de telles observation, afin de mieux comprendre ce qu'il se passe. L'une d'elles pourrait être aberrante et relever d'une erreur de mesure.

5. Sélection de variables

Dans certains cas, le nombre p de variables explicatives *(en incluant la constante)* est très, voire trop grand, occasionnant des problèmes :

- de redondance entre certaines variables
- ou de variables parfois peu explicatives...
- ... mais créant un problème de sur-apprentissage.

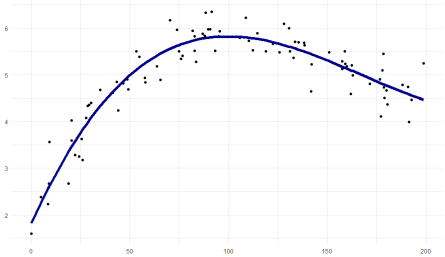

(a) Ajustement « raisonnable », $R^2 \approx 0.85$.

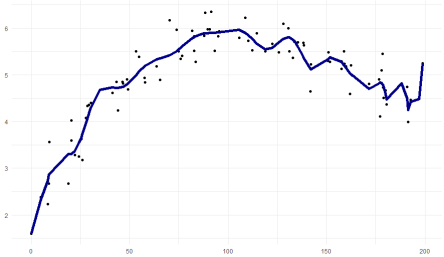

(b) Sur-ajustement, $R^2 \approx 0.91$.

On pourrait essayer tous les modèles possibles, et retenir le « meilleur » *(critère R_a^2, AIC, BIC,etc...)* ...

... mais on se retrouve à ajuster $2^p - 1$ modèles, ce qui peut être incalculable en un temps raisonnable si p est grand.

Dans cette section, on va présenter deux méthodes progressives de sélection des variables.

5.1 La méthode ascendante « forward »

Principe

On cherche à expliquer une variable Y à partir de p variables explicatives $X_1, \ldots, X_p$.

- On construit d'abord un modèle avec une seule variable explicative :
  - on ajuste les p modèles à une variable ;
  - on choisit ensuite celui avec le meilleur coefficient R^2.
- Ensuite, on construit un modèle avec deux variables explicatives :
  - la 1ère est celle choisie précédemment ;
  - on ajuste ensuite les $p - 1$ modèles à deux variables ;
  - on choisit ensuite celui avec le meilleur coefficient R^2.
- On répète ensuite cette procédure, en ajoutant à chaque étape k une nouvelle variable, choisie comme étant celle améliorant le plus le coefficient R^2 parmi les $p - k$ variables restantes.
- Jusqu'à avoir le modèle complet avec p variables.

On se retrouve ainsi avec p modèles $\mathcal{M}_1, \ldots, \mathcal{M}_p$, où pour chaque $k \in \{1, \ldots, p\}$, $\mathcal{M}_k$ est un modèle à k variables explicatives.

Comment choisir parmi ces modèles ?

On choisit simplement le modèle :

- avec le meilleur critère *AIC (le plus petit pssoible)* ;
- ou bien avec le meilleur critère *BIC (le plus petit possible)*,
- ou bien le meilleur coefficient de détermination ajusté R_a^2 *(le plus grand possible)* ;
- ou bien avec la meilleur erreur de prévision *(la plus petite possible, estimée par validation croisée par exemple)* ;
- ou bien en optimisant un autre critère *(Mallow's C_p, ...)*.

Remarque :

- Il se peut qu'aucun des modèles $\mathcal{M}_1, \ldots, \mathcal{M}_p$ ne contienne en fait le meilleur modèle parmi les $2^p - 1$ possibles.
- Cette méthode ne permet donc pas de trouver le meilleur modèle possible.
- Simplement le meilleur parmi une collection de modèles judicieusement choisie.

Exemple (*Jus de pommes*)

On a comparé 100 jus de pommes différents, caractérisés par différentes mesures, et un score de qualité du jus.

	pH	sugar	turbidity	color	polyphenols	viscosity	ascorbic_acid	quality
1	3.4	10.9	7.2	42.8	196.3	1.1	35.4	77.3
2	3.5	12.4	6.3	42.5	141.6	1.1	29.9	60.1
3	3.8	11.6	4.7	40.6	168.3	1.3	29.8	68.1
4	3.5	11.5	5.5	39.5	198.6	1.3	22.4	76.6
5	3.5	10.6	4.6	45.6	233.5	1.0	34.0	87.2
6	3.8	11.9	4.5	53.3	117.5	1.2	28.9	54.2

On cherche à expliquer la variable *quality* en fonction des autres par un modèle linéaire.

Exemple (*Jus de pommes*)

On utilise la procédure « forward » via la fonction `regsubsets` du package `leaps` de R.

```
mod_forward <- regsubsets(x=quality~.,data=df_juice,method="forward")
summary(mod_forward)
```

```
         pH  sugar turbidity color polyphenols viscosity ascorbic_acid
1  ( 1 ) " " " "   " "       " "   "*"         " "       " "
2  ( 1 ) " " "*"   " "       " "   "*"         " "       " "
3  ( 1 ) " " "*"   " "       " "   "*"         " "       "*"
4  ( 1 ) " " "*"   " "       "*"   "*"         " "       "*"
5  ( 1 ) " " "*"   " "       "*"   "*"         "*"       "*"
6  ( 1 ) " " "*"   "*"       "*"   "*"         "*"       "*"
7  ( 1 ) "*" "*"   "*"       "*"   "*"         "*"       "*"
```

Ce résumé nous indique dans quel ordre sont les variables choisies par la méthode de sélection « forward ».

Exemple (*Jus de pommes*)

On peut aussi l'afficher sous forme de graphique.

```
plot(mod_forward,scale="r2",main="Procédure forward de sélection des variables")
```

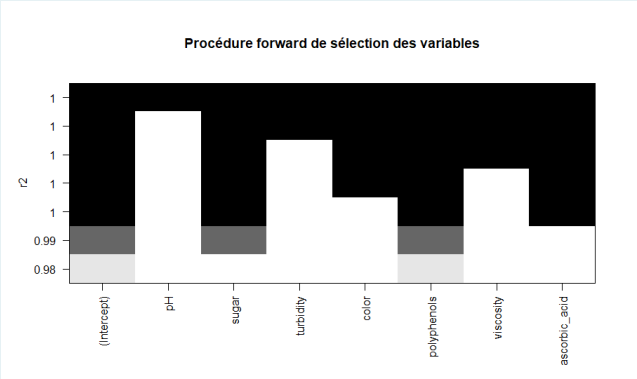

Exemple (*Jus de pommes*)

On peut dorénavant choisir le meilleur modèle parmi la collection crée d'après le critère *AIC*, *BIC* ou R_a^2.

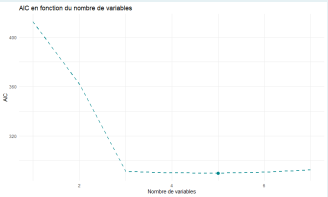

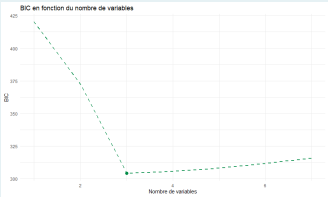

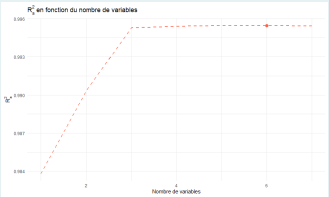

On choisit :

- 5 variables avec le critère *AIC* ;
- 3 variables avec le critère *BIC* ;
- 6 variables avec le critère R_a^2.

On peut alors regarder à nouveau le résumé de l'objet `mod_forward` pour savoir quelles variables sont finalement retenues.

5.2 La méthode descendante « backward »

Principe

On cherche à expliquer une variable Y à partir de p variables explicatives $X_1, \ldots, X_p$.

- On construit d'abord le modèle avec les p variables explicatives :
- Ensuite, on construit un modèle avec $p - 1$ variables explicatives :
  - on ajuste les $p - 1$ modèles avec $p - 1$ variables ;
  - on choisit ensuite celui avec le meilleur coefficient R^2.
- On répète ensuite cette procédure, en retirant à chaque étape k une nouvelle variable, choisie comme étant celle détériorant le moins le coefficient R^2 parmi les $p - k$ variables restantes.
- Jusqu'à avoir le modèle nul n'ayant aucune variable, si ce n'est la constante.

Comme pour la méthode « forward », on se retrouve ainsi avec p modèles $\mathcal{M}_1, \ldots, \mathcal{M}_p$, où pour chaque $k \in \{1, \ldots, p\}$, $\mathcal{M}_k$ est un modèle à k variables explicatives.

On choisit ensuite le modèle avec le meilleur critère *AIC*, *BIC*, R_a^2, *Mallow's* C_p, etc...

Remarque : Comme précédemment, cette méthode n'offre aucune garantie de choisir le meilleur modèle possible, mais le meilleur parmi une collection de modèles choisie judicieusement.

Exemple (*Jus de pommes*)

Revenons à notre exemple de jus de pommes, sur lequel on va appliquer la méthode « backward ».

```
mod_backward <- regsubsets(x=quality~.,data=df_juice,method="backward")
summary(mod_backward)
```

```
         pH  sugar turbidity color polyphenols viscosity ascorbic_acid
1  ( 1 ) " " " "   " "       " "   "*"         " "       " "
2  ( 1 ) " " "*"   " "       " "   "*"         " "       " "
3  ( 1 ) " " "*"   " "       " "   "*"         " "       "*"
4  ( 1 ) " " "*"   " "       "*"   "*"         " "       "*"
5  ( 1 ) " " "*"   " "       "*"   "*"         "*"       "*"
6  ( 1 ) " " "*"   "*"       "*"   "*"         "*"       "*"
7  ( 1 ) "*" "*"   "*"       "*"   "*"         "*"       "*"
```

Exemple (*Jus de pommes*)

On peut aussi l'afficher sous forme de graphique.

```
plot(mod_backward,scale="r2",main="Procédure backward de sélection des variables")
```

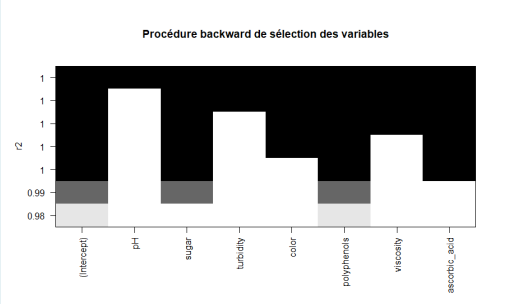

Ici, inutile d'aller plus loin : on retrouve exactement les mêmes modèles qu'avec la procédure de sélection « forward ». On choisira donc à la fin le même modèle, quelque soit le critère utilisé.

Attention : ce n'est pas toujours le cas...